Süzgeç – Dijital Bağımlılık Fikir Önerisi (Idea Proposal)

Samsung Innovation Campus & Yeşilay Capstone Projesi

1. Proje Fikri

Problem. Kullanıcılar bir şeyi kaçırma kaygısıyla (FoMO) telefonu günde yaklaşık 85 kez kontrol ediyor; kontrollerin yarısından fazlası 30 saniyeden kısa (Andrews ve ark., 2015). Bildirimler bu döngüyü besliyor, kumar ve kampanya bildirimleri kullanıcıyı bağımlılık yaratan içeriğe çekiyor; bildirimleri tamamen kapatmak ise kaygıyı ve FoMO'yu artırıyor (Fitz ve ark., 2019).

Çözüm. Süzgeç, telefonu Rahatsız Etmeyin modunda tutup her bildirimi gönderen, uygulama, içerik ve saate göre beş kategoriye ayıran bir Android uygulamasıdır: Kritik ve Önemli bildirimler sesle anında gelir, Normal ve Önemsiz bildirimler seçilen saatlerde günde 3 kez özetle teslim edilir, kullanıcının seçtiği bağımlılık türüne (kumar, alışveriş kampanyası, sosyal medya) ait bildirimler silinir.

Hedef kitle. 18 yaş üstü, amiral gemisi olmayan Android telefon kullanıcıları; öncelikle üniversite öğrencileri.

Somut hedef. Kritik bildirimlerin en az %95'ini kaçırmadan sesli/titreşimli bildirimleri en az %50 azaltmak, kilit açmayı da azaltmak (Fitz ve ark.'nda günde yaklaşık 57'den 38'e indi) ve FoMO'yu artırmamak.

2. Literatür Örnekleri

Fitz ve ark. (2019), *Computers in Human Behavior*. Süzgeç'in temel ilham kaynağı olan bu randomize saha deneyinde (237 kişi) günde 3 toplu teslim kilit açmayı azalttı ($d = -0{,}60$); hiç bildirim almamak ise kaygıyı ve FoMO'yu artırdı. Yazarların sınırlılık saydığı önem ayrımı eksikliği, Süzgeç'in doldurduğu boşluktur.

Visuri ve ark. (2019), *Int. J. Human-Computer Studies*; Lin ve ark. (2024), *Proc. ACM IMWUT*. Visuri ve ark.'nda telefonda çalışan, kullanıcı etiketleriyle eğitilen bir karar ağacı bildirimi gösterme/gizleme kararını %91,1 doğrulukla verdi. Lin ve ark.'nda genel otomatik sıralama yalnız %13,8 oranında tercih edildi; kullanıcılar düzeltmelerinden öğrenen bir sistem istedi.

3. Veri

Veri	Kaynak, format ve boyut	Etiket ve kullanım
Sentetik Türkçe bildirimler	Kendi üretimimiz (şablon + LLM); JSONL; 5.000–10.000 örnek	11 içerik türü; ana eğitim
Türkçe SMS ve e-posta setleri	TurkishSMSCollection, Uysal ve ark. (2013), UCI Turkish Spam; ~5.600 SMS + 826 e-posta	Spam/normal → içerik türü; eğitim
Ekip bildirimleri	Ekibimizin telefonlarından gerçek bildirimler (onamlı, maskelenmiş); JSONL	Çift etiketleme (kappa ≥ 0,70); yalnız test
Açık kayıtlar	Komninos ve ark. (2018, 2019), LSApp (2021); ~406 bin bildirim, ~600 bin uygulama kaydı	Etiketsiz; betimsel analiz

Hedef değişkenler ve ön işleme. Model kişiden bağımsız 11 içerik türünü (ör. para hareketi, kampanya, kumar tanıtımı) öğrenir; tür, kullanıcı ayarlarıyla 5 kategoriye eşlenir, kutu içi sıra kullanıcının düzeltmelerinden öğrenilir. Servis bildirimleri bayraklarla ve 5 saniye kuralıyla ayıklanır, kişisel bilgiler maskelenir, Türkçe küçük harf normalizasyonu yapılır, test seti kullanıcıya ve zamana göre ayrılır.

4. Yaklaşım (Makine Öğrenmesi veya Derin Öğrenme)

Seçim: hibrit — metin için derin öğrenme, bağlam ve kişiselleştirme için makine öğrenmesi. Aramalar, alarmlar ve öncelikli uygulamalar kural katmanıyla modelden önce işlenir.

- **Derin öğrenme:** "Hesabınızdan 2.500 TL çekildi" (Kritik) ile "Kartınıza 2.500 TL'ye varan puan fırsatı" (kampanya) aynı kelimeleri paylaşıp zıt önem taşıyor; bunları ayırmak için küçük bir Türkçe BERT (turkish-mini-bert, 11,6M parametre) ince ayarlanıp telefona taşınır. Veri az olduğu için sıfırdan eğitim yapılmaz.
- **Taban ve yedek model:** TF-IDF + lojistik regresyon; BERT onu geçemez ya da 50 ms'yi aşarsa demo bununla çalışır.
- **Bağlam için makine öğrenmesi:** Uygulama, gönderen ve saat verisinde klasik yöntemler LSTM kadar başarılı (Katevas ve ark., 2017).
- **Kişiselleştirme:** Kullanıcının kategori taşımaları cihazda sayaç tabanlı bir düzeltmeyle uygulanır; sıra düzeltmeleri için LightGBM LGBMRanker (NDCG@5) denenir.